

Промежуточный отчет по программному проекту

1. Основные планы и этапы проекта

1.1 Краткое описание проекта:

«Система поиска, категоризации и скоринга крипто-аккаунтов в Twitter» — это веб-сервис, реализующий пайплайн анализа крипто-контента с использованием гибридного подхода (ML-классификаторы + LLM). Система начинается с модели определения принадлежности контента к крипто-тематике, затем классифицирует тип утверждения и извлекает ключевые данные, после чего LLM анализирует информацию и формирует структурированный запрос для проверки достоверности через сравнение с рыночными данными. На основе агрегированных результатов система оценивает общую надежность крипто-аккаунта.

Название проекта:

«Система поиска, категоризации и скоринга крипто-аккаунтов в Twitter»

Цель проекта:

Разработать систему автоматической оценки надежности крипто-аккаунтов в Twitter с использованием гибридного пайплайна (ML + LLM). Система позволит пользователям проверять достоверность крипто-прогнозов, анализировать паттерны поведения авторов и получать общий скоринг надежности аккаунта на основе проверяемых рыночных данных.

Краткое описание задач:

1. Разработка технического задания с учетом гибридной архитектуры пайплайна (ML + LLM).
2. Поиск и подготовка датасетов для обучения модели классификации крипто-тематки.
3. Создание и обучение модели определения принадлежности твитов к крипто-тематике.
4. Разработка модуля сбора крипто-твитов автора через requests с использованием токенов.
5. Создание ML-модуля классификации типа утверждений в крипто-твитах (прогноз, новость, мнение, призыв).
6. Разработка модуля извлечения ключевых данных из прогнозных твитов (название токена, целевая цена, временной горизонт).
7. Интеграция LLM для формирования структурированных запросов к внешним API на основе извлеченных данных.
8. Реализация сервиса верификации ценовых прогнозов через рыночные API (CoinGecko/Binance).
9. Разработка системы агрегации и скоринга авторов крипто-контента.
10. Создание веб-интерфейса для взаимодействия с пользователем.
11. Тестирование и оптимизация пайплайна (особенно проверка ценовых прогнозов).
12. Подготовка программной документации и защита проекта.

1.2 Планы и этапы выполнения проекта

Этап проекта	Описание работ	Ожидаемые результаты	Сроки выполнения
Обоснование необходимости разработки	Постановка задачи и анализ проблематики дезинформации в крипто-пространстве Twitter. Сбор теоретических материалов по ML, LLM, фактчекингу крипто-контента	Определены цели проекта, собрана теоретическая база по анализу крипто-твитов	13.11.25
Разработка и утверждение технического задания	Определение требований к программному продукту. Выбор гибридной архитектуры (ML + LLM). Спецификация API для работы с крипто-данными. Разработка и согласование технического задания с научным руководителем. Загрузка согласованного технического задания в SmartLMS	Готовое техническое задание для начала разработки системы анализа крипто-аккаунтов	01.12.25 – 16.12.25
Научно-исследовательский этап разработки	Исследование методов определения крипто-тематики в текстах. Анализ доступности данных через requests с токенами. Изучение LLM-решений для анализа текста. Исследование рыночных данных API (CoinGecko, Binance). Определение метрик оценки для крипто-контента	Выбраны технологии и подходы для гибридного анализа крипто-твитов	15.11.25 – 15.12.25
Поиск и подготовка баз данных для обучения	Поиск открытых датасетов крипто-твитов (Crypto Twitter Datasets, Kaggle datasets). Сбор дополнительных данных через requests с токенами. Разметка данных для обучения моделей определения крипто-тематики и классификации утверждений. Подготовка тренировочных и тестовых выборок	Подготовленные датасеты для обучения ML-моделей (10,000+ размеченных твитов)	15.12.25 – 30.12.25
Разработка модели определения крипто-тематики	Обучение ML-модели на подготовленных датасетах для классификации принадлежности твитов к крипто-тематике. Валидация и тестирование модели. Оптимизация гиперпараметров. Документирование процесса обучения	Рабочая модель для фильтрации крипто-контента с точностью >85%	01.01.26 – 14.01.26

Этап проекта	Описание работ	Ожидаемые результаты	Сроки выполнения
Разработка ML-модулей классификации и извлечения	Создание ML-модели классификации типа утверждений в крипто-твитах. Разработка модуля извлечения ключевых данных из прогнозных твитов (токен, цена, время). Создание модуля сбора крипто-твитов через requests с использованием токенов	Рабочие ML-модули для первичной обработки крипто-твитов	15.01.26 – 31.01.26
Интеграция LLM и разработка модуля верификации	Настройка и интеграция LLM (локальная или облачная) для формирования структурированных JSON-запросов. Разработка модуля верификации ценовых прогнозов через CoinGecko API. Создание системы агрегации результатов по авторам крипто-контента. Реализация функционала проверки трасовости прогнозных постов	Рабочий пайплайн проверки крипто-прогнозов с использованием LLM и внешних API	01.02.26 – 20.02.26
Интеграция и разработка интерфейса	Объединение модулей в единый пайплайн анализа крипто-аккаунтов. Разработка серверной части (FastAPI) с бизнес-логикой. Создание веб-интерфейса для взаимодействия с пользователем. Реализация визуализаций результатов анализа крипто-контента	Готовый веб-сервис для анализа крипто-аккаунтов	21.02.26 – 15.03.26
Тестирование и оптимизация	Тестирование ML-моделей на крипто-датасетах. Тестирование модуля сбора данных через requests. Юзабилити-тестирование интерфейса. Нагрузочное тестирование пайплайна. Оптимизация производительности системы. Корректировка программы по результатам испытаний. Фокус на тестировании верификации ценовых прогнозов	Протестированная и оптимизированная система анализа крипто-аккаунтов	15.03.26 – 30.03.26
Подготовка и передача программы	Подготовка программы и программной документации для презентации и защиты. Представление разработанного программного продукта научному руководителю и	Получение готового продукта для анализа крипто-аккаунтов и защита работы	15.02.26 – 10.04.26

Этап проекта	Описание работ	Ожидаемые результаты	Сроки выполнения
	получение отзыва. Загрузка Пояснительной записки в систему Антиплагиат через ЛМС НИУ ВШЭ. Загрузка материалов курсового проекта в ЛМС, дисциплина «Курсовой проект, 2 курс, ПИ». Защита программного продукта комиссии		

2. Используемый технологический стек и его обоснование

2.1 Перечень используемых технологий

Технология/Инструмент	Описание	Причины выбора
Python 3.8+	Основной язык программирования для ML-разработки и backend	Стандарт для машинного обучения, богатая экосистема библиотек
Transformers (HuggingFace)	Библиотека для работы с NLP-моделями	State-of-the-art модели для классификации текста и извлечения сущностей
Scikit-learn, Pandas, NumPy	Библиотеки для обработки данных и ML	Стандартные инструменты для работы с данными и ML в Python
LLM (GPT-4 API или локальная модель)	Large Language Model для анализа и структурирования данных	Мощный инструмент для понимания контекста и формирования структурированных запросов на основе неформатированного текста
Requests	Библиотека для HTTP-запросов	Для получения твитов через неофициальные эндпоинты с использованием токенов
FastAPI	Фреймворк для создания веб-API	Высокая производительность, автоматическая документация, простота разработки
CoinGecko API / Binance API	API для получения рыночных данных по криптовалютам	Бесплатный доступ к историческим данным по криптовалютам для верификации прогнозов

Технология/Инструмент	Описание	Причины выбора
HTML/CSS/JavaScript	Технологии для веб-интерфейса	Стандарт для создания кросс-платформенного веб-интерфейса
Docker	Платформа для контейнеризации	Упрощение развертывания и обеспечения воспроизводимости среды
Git	Система контроля версий	Управление версиями кода, удобство командной работы

2.2 Обоснование выбранного технологического стека

Использование языка программирования **Python** для реализации системы анализа крипто-аккаунтов имеет следующие преимущества:

- 1. Экосистема для ML: Python предоставляет богатейший набор библиотек для машинного обучения (scikit-learn, transformers, torch), что критично для задач классификации крипто-контента и анализа текста.
- 2. Простота и читаемость: Python позволяет быстро прототипировать и итерировать ML-модели для анализа крипто-твитов.
- 3. Интеграция с API: Отличная поддержка HTTP-запросов через библиотеку requests, что необходимо для сбора данных через токены.
- 4. Сообщество и документация: Большое количество ресурсов и готовых решений для анализа текстовых данных.

Выбор **HuggingFace Transformers** для NLP-задач обусловлен:

- 1. State-of-the-art модели: Библиотека предоставляет предобученные модели (BERT, RoBERTa), которые эффективны для определения крипто-тематики и классификации утверждений.
- 2. Простота fine-tuning: Легкая адаптация моделей под специфику крипто-контента.
- 3. Активная разработка: Постоянные обновления и улучшения моделей.

LLM (GPT-4 или локальная модель) используется для:

- 1. Глубокого понимания контекста: Анализ сложных формулировок, иронии и скрытых смыслов в крипто-твитах.
- 2. Формирования структурированных запросов: Преобразование неформатированного текста твита в четкий JSON для запроса к рыночным API.
- 3. Гибкости: Возможность легко адаптировать систему к новым типам крипто-утверждений через промпт-инжиниринг.

Requests используется для сбора данных вместо Twitter API v2, так как:

1. Гибкость работы с неофициальными эндпоинтами: Позволяет обходить ограничения официального API.
2. Простота использования с токенами: Легкая интеграция с существующими системами аутентификации.
3. Меньшие ограничения: В некоторых случаях предоставляет более широкий доступ к историческим данным.
4. Контроль над запросами: Позволяет тонко настраивать параметры сбора данных.

FastAPI выбран в качестве backend-фреймворка, потому что:

1. Высокая производительность: Основан на Starlette и Pydantic, что обеспечивает высокую скорость обработки запросов.
2. Автоматическая документация: Генерация OpenAPI и Swagger UI из кода.
3. Асинхронность: Поддержка async/await для эффективной работы с внешними API.

CoinGecko API используется для рыночных данных, так как:

1. Специализация на крипто-данных: Фокусируется именно на криптовалютах, что идеально подходит для проекта.
2. Бесплатный доступ: Предоставляет достаточный лимит запросов для курсового проекта.
3. Надежность: Популярный и стабильный источник данных в крипто-сообществе.

Docker применяется для:

1. Воспроизводимости среды: Гарантия, что система будет работать одинаково на разных машинах.
2. Упрощения развертывания: Контейнеризация всех компонентов системы анализа крипто-аккаунтов.
3. Изоляции зависимостей: Отдельные контейнеры для ML-моделей, LLM, backend и frontend.

Git используется, так как:

1. Контроль версий: Особенно важно для итеративной разработки ML-моделей.
2. Коллаборация: Упрощает работу над разными компонентами системы.
3. Бэкап кода: Сохранение истории изменений всех модулей анализа.

3. Критерии оценивания проекта

Критерий	Описание
Качество подготовленных датасетов	Количество размещенных крипто-твитов в обучающей выборке (цель: 10,000+)
Точность определения крипто-тематики	Accuracy/F1-score модели классификации крипто-твитов (>85%)
Точность классификации типа утверждений	Точность определения типов утверждений в крипто-твитах (прогнозы, новости, мнения, призывы)

Критерий	Описание
Эффективность извлечения данных	Точность извлечения ключевых параметров из прогнозных твитов (токен, цена, время)
Качество работы LLM-модуля	Стабильность формирования корректных JSON-структур для запросов к API
Эффективность верификации прогнозов	Процент успешных проверок ценовых прогнозов через рыночные API. Погрешность верификации (< 15% считается успешным)
Производительность пайплайна	Время полного анализа крипто-аккаунта (< 2 минут)
Функциональность — Процент выполнения функциональных требований	Выполненные требования в процентах от общего количества, включая обязательную проверку прогнозов цен
Функциональность — Количество реализованных функций	Абсолютное количество функций, которые работают правильно
Документация и оформление — Полнота документации (%)	Процент от требуемого объема документации
Документация и оформление — Процент закомментированных строк (%)	Процент закомментированных строк относительно общего количества строк кода
Соблюдение сроков и плана — Процент выполнения работы в срок (%)	Процент задач, выполненных в срок
Соблюдение сроков и плана — Количество дней отклонения от плана	Общее число дней отклонения от плана
Использование технологического стека — Процент использования функциональности стека (%)	Процент использования функциональности выбранного стека технологий